



High-Level Design

Plataforma FinOps SaaS — Azure-Only

Versión 1.0 — 2026-09-07

CSCloudSolutions

Cloud Solutions & FinOps Consulting

AZURE-ONLY

MULTI-TENANT

NEXT.JS 16

TERRAFORM

HLD ARCHITECTURE

© 2026 CSCloudSolutions. Todos los derechos reservados. — CONFIDENCIAL

High-Level Design (HLD) — CSCloudSolutions FinOps Platform

Versión: 1.1
 Fecha: 2026-08-03
 Autor: Equipo de Arquitectura Cloud & FinOps — CSCloudSolutions
 Estado: Aprobado para Producción


1. Resumen Ejecutivo y Visión Estratégica

1.1 Propósito del Producto

CSCloudSolutions FinOps Platform es un SaaS empresarial multi-tenant, **Azure-only**, diseñado para proporcionar observabilidad financiera, optimización continua de costos, gobernanza automatizada y simulación de escenarios sobre la infraestructura cloud en Microsoft Azure. La plataforma aborda la complejidad creciente del modelo de facturación cloud mediante la ingesta, normalización y análisis de telemetría de costos e inventario, permitiendo a los equipos de FinOps, Ingeniería y Finanzas tomar decisiones informadas basadas en datos unitarios y en tiempo real.

1.2 Alineación con el FinOps Framework

La arquitectura de CSCloudSolutions FinOps implementa de manera nativa las tres fases del ciclo de vida definido por el **FinOps Foundation Framework**:



- INFORM (Informar):** Asignación precisa de costos por Tenant, Centro de Costos, Suscripción y Tags. Telemetría de uso MTD (Month-To-Date), proyección a fin de mes, dashboards interactivos configurables y exportación estandarizada bajo el formato **FOCUS 1.0** (FinOps

- Open Cost and Usage Specification).
- **OPTIMIZE (Optimizar):** Identificación automatizada de recursos no utilizados o sobredimensionados (*Zombie Resources*), motor de rightsizing de Virtual Machines y App Services, recomendaciones de Azure Advisor, y gestión del ciclo de vida de Reservas e Savings Plans (RI/SP).
 - **OPERATE (Operar):** Automatización de acciones de gobierno mediante apagado/encendido programado de VMs (*Power Schedules*), políticas de tiempo de vida de recursos (*TTL Policies*), cumplimiento de políticas de etiquetado (*Tag Inheritance & Enforcement*) y remediación guiada con RBAC.

1.3 Matriz de Tiers y Modelo de Negocio


El SaaS opera bajo un modelo de suscripción freemium/tiered con pago integrado vía **Paddle**:

CAPACIDAD / DIMENSIÓN	TIER PROFESSIONAL	TIER BUSINESS	TIER ENTERPRISE
Suscripciones Azure	Hasta 2 suscripciones	Hasta 3 suscripciones	Ilimitadas / Custom
Usuarios por Tenant	Hasta 3 usuarios	Hasta 5 usuarios	Ilimitados
Frecuencia de Sync	6 horas	1 hora	10 minutos (Real-time)
Retención de Reportes PDF/JSON	90 días	180 días	365 días
Retención Histórica FOCUS	12 meses	36 meses	Personalizada
Módulos Incluidos	Core Dashboard, Cost MTD, Export Básico, +Anomalías Z-score, +Copilot IA básico	+Simulador What-If, +Cost Groups, +Remediación	Todo + SSO Enterprise + SLA 99.9% + Data Residency
Autenticación	Entra ID MSAL	Entra ID MSAL	Entra ID MSAL + WorkOS SAML/OIDC SSO

2. Arquitectura Global de Sistema y Dominio

2.1 Diagrama de Arquitectura de Alto Nivel (C4 - System Context & Containers)

La plataforma se despliega en una arquitectura de **Stamp Regional** dentro de Microsoft Azure (región primaria **westus2**), protegida perimetralmente por **Cloudflare** para WAF, CDN y gestión de DNS.



2.2 Desglose de Capas del Sistema

A. Capa de Presentación (Client Layer)

- **Framework UI:** React 19 / Next.js 16 (App Router) con Renderizado Servidor-Primero (RSC).
- **Internacionalización (i18n):** **next-intl** con soporte nativo y sincronizado para 3 idiomas (**es** , **en** , **pt-BR**), alcanzando 4,114 keys traducidas por idioma.
- **Componentes Interactivos:** Recharts para gráficos de tendencias/forecast, React Grid Layout para widgets editables, cmdk para Command Palette (**Cmd+K**), y Tailwind CSS 4 para diseño responsivo y accesible.

B. Capa de Aplicación y Backend (API & Business Logic)

- **Next.js App Router API Routes:** 238 endpoints REST integrados con validación de tipos TypeScript.
- **Services & Collectors Layer:** 26 servicios de negocio especializados (`anomalyDetectionService` , `reservationService` , `powerScheduleService` , `budgetService` , `governanceReportingService` , `remediationService`) y 29 módulos colectores agnósticos (`collectors/azure/billingService` , `resourceGraphService` , `advisorService`).
- **Protección Middleware:** Control estricto de acceso basado en roles (RBAC) y Tenants vía `requestAuth.ts` (`requireTenantAccess` , `requireTenantRole` , `requireTenantTier` , `requireSuperAdmin`).

C. Capa de Cómputo y Procesamiento Asíncrono (Workers & Cron Jobs)


- **Azure Container Apps:** Despliegue de la aplicación principal como un contenedor inmutable (Node.js 22 Alpine, Next.js standalone).
- **Container App Jobs:** 15 tareas programadas independientes (*cron jobs*) aisladas para ingesta de datos, precalentamiento de caché, evaluación de anomalías, backfill histórico, alertas de expiración y exportaciones estandarizadas.

D. Capa de Persistencia y Caché (Data & Security State)

- **Azure MySQL Flexible Server:** Persistencia relacional primaria en MySQL Flexible Server con TLSv1.2, motor InnoDB, collation `utf8mb4_unicode_ci` y pool de conexiones optimizado (`mysql2`).
- **Azure Managed Redis:** Caché de alto rendimiento (Balanced B3, HA) utilizando `ioredis` con patrón **Stale-While-Revalidate (SWR)** y locks distribuidos para deduplicación de consultas hacia Azure.
- **Azure Key Vault:** Custodia y aislamiento de secretos de infraestructura (credenciales DB/Redis/Cron) y Service Principals de los tenants de clientes (`tenant-{tenantId}-client-id` / `secret`).

3. Desglose de Capacidades FinOps

La plataforma estructura sus funciones en 4 módulos operativos principales:



3.1 Módulo INFORM (Visibilidad y Asignación)

- **MTD & Daily Cost Tracking:** Cálculo exacto del gasto acumulado del mes (*Month-To-Date*), costo del día anterior (*Yesterday Cost*) y proyección matemática a cierre de mes basada en promedios ponderados y variaciones estacionales.
- **Multi-Currency & FX Engine:** Conversión dinámica entre monedas de origen de Azure (USD, EUR, BRL, ARS) con persistencia de tipos de cambio históricos en la tabla `FxRates` .

- **Cost Groups Customizables:** Agrupación lógica de recursos por unidades de negocio, aplicaciones o ambientes (Dev/Staging/Prod) sin modificar la infraestructura subyacente.
- **Estándar FOCUS 1.0:** Mapeador y exportador nativo compatible con la norma abierta FOCUS 1.0, permitiendo interoperabilidad y reporting estandarizado.

3.2 Módulo OPTIMIZE (Eficiencia y Ahorro)

- **Zombie Resources Scanner:** Detección automática de discos no adjuntados (*unattached Managed Disks*), IPs públicas sin asociar, Network Interfaces huérfanas, Snapshots obsoletos y Load Balancers vacíos.
- **Rightsizing Engine:** Motor analítico que cruza métricas de CPU/RAM/IOPS de ARM Monitor con costos de SKU para recomendar desescalados óptimos (*downgrades*) o cambios de familia de instancias.
- **Commitment Manager (RI / SP):** Cobertura y recomendaciones de compra/modificación de Reservas de Instancias (*Reserved Instances*) y Savings Plans con análisis de ROI y período de amortización.

3.3 Módulo OPERATE (Gobernanza y Automatización)

- **Power Scheduling:** Programación de apagado y encendido automático de máquinas virtuales no productivas fuera del horario laboral, calculando el ahorro estimado en USD.
- **Tag Governance & Inheritance:** Motor de verificación y heredado de etiquetas desde Resource Groups hacia Recursos hijo, con alertas de incumplimiento de política.
- **TTL Policy Enforcement:** Asignación de tiempo de vida máximo (*Time-To-Live*) a recursos temporales o de prueba, con flujo de notificación previa y eliminación automática o solicitada.
- **Remediation Actions Framework:** Sistema de acciones con aprobación (Delete, Deallocate, Downgrade, Retag) respaldado por `RemediationRequests` y registro auditables en `ActionLogs`.

3.4 Módulo AI & Copilot Assistant

- **Global Copilot Integrado:** Asistente conversacional basado en **Vercel AI SDK** y **Google Gemini**, capaz de interpretar consultas en lenguaje natural sobre costos y recursos ("¿Por qué subió el costo en la suscripción X este fin de semana?").
- **What-If Simulator:** Simulador de escenarios que proyecta el impacto económico de migraciones, apagados de cargas o compras de reservas antes de ejecutarlos en Azure.
- **AI Cost Analytics (Enterprise):** Vista de costo por modelo y tendencia de tokens para **Microsoft Foundry / Azure OpenAI**, priorizando tokens desde Azure Monitor (`ProcessedPromptTokens` , `GeneratedTokens` , `ProcessedInferenceTokens`) y fallback a costo agregado desde Cost Management cuando no hay desglose de tokens.
- **RBAC mínimo para AI Cost Analytics:** no introduce roles nuevos; reutiliza `Reader` , `Cost Management Reader` , `Monitoring Reader` y `Billing Reader` bajo principio de menor privilegio.


3.5 Módulo Integration Services (iPaaS)

- **Hub dedicado en Inteligencia:** `/intelligence/integration-services` con tabs para Logic Apps, APIM, Service Bus, Event Grid, Event Hubs y ADF.
- **Modelo operativo común:** cada tab expone metadatos transversales (suscripción, resource group, región, tags), costo acumulado/proyectado y estado de salud.
- **Logic Apps Enterprise Connectors:** separación explícita de conectores Standard vs Enterprise para priorizar impacto económico y operativo.
- **Consistencia UX FinOps/CMP:** filtros base, columnas base, orden A-Z/Z-A/costo, paginado 15/30/45/60 y columnas redimensionables.

4. Modelo Multi-Tenancy, Tiering y Gobernanza de Datos

4.1 Arquitectura Multi-Tenant


CSCloudSolutions FinOps utiliza un modelo de **Base de Datos Compartida con Discriminador por Tenant** (`tenantId`) y **Aislamiento Lógico Estricto**:



- **IDOR Prevention:** La regla de ESLint `local/no-unauth-tenant-id` evalúa en CI/CD que **toda ruta de API** que consuma `tenantId` contenga obligatoriamente un guard de `requestAuth.ts`.
- **Aislamiento de Secretos:** Cada tenant almacena sus credenciales de Service Principal de forma aislada en Azure Key Vault bajo la nomenclatura `tenant-{tenantId}-client-id` y `tenant-{tenantId}-client-secret`.

4.2 Patrón de Despliegue Stamp-Based y Data Residency

Para cumplir con regulaciones internacionales de residencia de datos (GDPR, LGPD, normativas bancarias), la plataforma implementa una infraestructura basada en **Stamps Regionales**:



- **Multi-Stamp Ready:** La variable `var.stamps` en Terraform permite aprovisionar réplicas completas de la infraestructura en diferentes regiones de Azure.
- **Residencia Configurable:** El campo `Tenants.data_residency` rige la ubicación física de las tablas de datos del tenant y su almacenamiento de blobs asociado.

5. Modelo de Seguridad, Identidad y Cumplimiento

5.1 Autenticación y Autorización (RBAC)

La plataforma soporta autenticación dual transparente:


1. **Microsoft Entra ID (MSAL Browser/React):** Autenticación nativa OIDC/OAuth 2.0. El token JWT emitido por Entra ID es validado en backend contra las claves públicas de Microsoft, verificando issuer, audience y tenant ID.
2. **WorkOS Enterprise SSO:** Autenticación SAML 2.0 / OIDC dedicada para clientes Enterprise con proveedores de identidad corporativos (Okta, Ping Identity, Azure AD Enterprise).

Matriz de Roles dentro del Tenant

ROL TENANT	PERMISOS DE LECTURA	CONFIGURAR BUDGETS/TAGS	EJECUTAR REMEDIACIÓN	ADMINISTRAR USUARIOS / CREDENTIALS
Reader	✔ Sí	✘ No	✘ No	✘ No
Analyst	✔ Sí	✔ Sí	✘ No	✘ No
Operator	✔ Sí	✔ Sí	✔ Sí (Aprobadas)	✘ No
Admin / Owner	✔ Sí	✔ Sí	✔ Sí (Directas)	✔ Sí

5.2 Hidratación y Aislamiento de Secretos (Key Vault Architecture)

Ningún secreto sensible (passwords de DB, claves de Redis, API keys de terceros, credenciales de Service Principals) existe en código ni en variables estáticas en disco.




5.3 Headers de Seguridad y Protección Web

Configuración activa en `next.config.ts` y verificada en auditorías Checkov:

- `X-Frame-Options: DENY` (Anti-Clickjacking)
- `X-Content-Type-Options: nosniff` (Anti-MIME Sniffing)
- `Referrer-Policy: strict-origin-when-cross-origin`
- `Permissions-Policy: camera=(), microphone=(), geolocation=(), payment=(), usb=()`
- `Strict-Transport-Security: max-age=31536000; includeSubDomains; preload` (HSTS)
- **Content Security Policy (CSP):** Restricción de scripts, estilos, objetos y conexiones hacia orígenes explícitamente autorizados (Cloudflare, Paddle, Microsoft, Google Fonts).

6. Arquitectura de Integraciones Cloud (Azure Platform)

La plataforma interactúa de manera no invasiva con los tenants de los clientes mediante un **Azure Service Principal (App Registration)** configurado con los permisos mínimos necesarios (Principio de Menor Privilegio):



6.1 Roles Azure Mínimos Requeridos en Tenant de Cliente

ALCANCE / SCOPE	ROL AZURE MÍNIMO	PROPÓSITO
Subscription / Management Group	Cost Management Reader	Ingesta de datos de costos MTD, históricos y presupuestos
Subscription	Reader	Lectura de inventario vía Resource Graph y métricas ARM
Resource Group (Opcional)	Desktop Virtualization Power On Off / Custom Role	Apagado/Encendido de VMs en Power Schedules

6.2 Resiliencia y Manejo de Rate Limits (429 Throttling)


El servicio `billingService.ts` implementa patrones avanzados de resiliencia frente a los límites de frecuencia de Azure Cost Management API:

- **Backoff Exponencial con Jitter:** Reintentos automáticos configurados hasta 5 niveles con retraso aleatorio.
- **Single-Flight Lock via Redis:** Deduplicación de peticiones concurrentes para el mismo tenant y ventana temporal.
- **Cache SWR:** Entrega de datos desde caché Redis mientras se revalida en segundo plano para evitar "cache stampede".


7. Modelo de Datos y Estrategia de Persistencia

7.1 Resumen del Esquema (84 Tablas Relacionales)

El esquema MySQL comprende 84 tablas agrupadas por dominios funcionales:




7.2 Estrategia de Caché de 3 Nivel con Redis




8. Flujos Operativos y Diagramas de Secuencia HLD

8.1 Flujo de Onboarding de Tenant Azure




8.2 Flujo de Recolección y Procesamiento de Costos MTD



9. Operación, Alta Disponibilidad, Resiliencia y CI/CD

9.1 Canalización de CI/CD (GitHub Actions)


El ciclo de integración y despliegue continuo se encuentra completamente automatizado mediante GitHub Actions:



9.2 Resiliencia y Estrategia de Disaster Recovery (DR)

- **MySQL Flexible Server:** Automated Backups con retención configurable de 30 días, Point-In-Time Restore (PITR) y arquitectura regional con réplica de lectura opcional.
- **Stateless Application Layer:** La capa Web Container Apps es completamente desprovista de estado (*stateless*). La pérdida de una instancia de contenedor provoca el auto-healing de Azure en < 15 segundos.
- **Caché Transient:** La pérdida del cluster Redis no interrumpe el servicio; la plataforma degrada suavemente a consultas directas contra MySQL y reintenta la conexión de Redis.

10. Hoja de Ruta de Arquitectura (Roadmap HLD)



1. **Expansión Multi-Stamp (Q3 2026):** Despliegue del Stamp **westeurope** para atención regional europea con cumplimiento LGPD/GDPR estricto.
2. **Auto-Remediación Autónomamente Guiada (Q4 2026):** Evolución del motor de remediación a un modelo basado en agentes autónomos controlados por políticas de riesgo configurables por el usuario.
3. **Soporte Amortizado FOCUS 1.1 (Q3 2026):** Incorporación completa de especificaciones FOCUS 1.1 para facturación unificada de compromisos multinivel.

11. Addendum 2026-08-03 — SuperAdmin Operations & Commercial Governance

11.1 SaaS Operations Control Plane (SuperAdmin)

Se incorpora un nuevo módulo de operaciones globales (`/superadmin/ops`) con visión consolidada de estado de plataforma:

- Salud de componentes SaaS (API, DB, Sync, colas y alertas).
- Estado de crons críticos por frescura de ejecución y severidad.
- Cobertura de canales de notificación para tenants administrados.
- Dispatch de notificaciones operativas desde un único punto de control.

Este módulo opera bajo principio de menor privilegio con acceso exclusivo `SUPERADMIN` y no expone datos de tenant a usuarios no autorizados.

11.2 Cron Reliability Layer

Se agrega una capa de observabilidad persistente para jobs programados:

- Registro de ejecución por cron (estado, duración, resumen y detalle).
- Evaluación de frescura contra expectativa de cadencia (on-time vs late).
- Señal temprana para detección de degradación operacional sin depender de logs efímeros del contenedor.

11.3 Commercial Metadata Governance

El dominio de gestión de tenants amplía metadatos comerciales por cliente:

- **Vendedor/Referido** (`sales_referrer`)
- **Comisión (%)** (`sales_commission_pct`)

Ambos campos quedan restringidos a operación de SuperAdmin y auditados (`updated_by` , `updated_at`) para trazabilidad financiera interna.

12. Addendum 2026-08-22 — Dominio de Gobernanza Operativa y Ciclo de Vida del Gasto

12.1 Dos dominios nuevos en el mapa de capacidades

La plataforma incorpora dos dominios funcionales que cierran el ciclo entre *detectar* un desperdicio y *eliminarlo* con control:

- **Limpieza de Nube (Cloud Waste Lifecycle)**. Detección continua de recursos huérfanos, gobernanza de ciclo de vida por TTL y auditoría de backups sin origen. Cubre el desperdicio duro —lo que factura sin entregar valor— y el blando —lo que factura sin dueño identificable.
- **Gobernanza Operativa**. Automatización de energía de cómputo, prevención de costos desde el aprovisionamiento con Azure Policy, reporting ejecutivo de postura, resiliencia arquitectónica, ciclo de vida de credenciales de identidad y flujo de aprobación de cambios.

12.2 Principio arquitectónico: prevención antes que remediación


El dominio de Gobernanza se ordena sobre tres momentos del gasto, en orden de valor decreciente:

1. **Prevenir** (Azure Policy con efecto `Deny`): el costo indeseado nunca se aprovisiona. Es el único mecanismo con ahorro del 100% y esfuerzo operativo cero por recurso.
2. **Corregir automáticamente** (`Modify` / `DeployIfNotExists` , herencia de etiquetas, apagado programado): el costo existe pero se ajusta sin intervención humana por caso.
3. **Remediar con aprobación** (borrado, redimensionamiento, cambio de tier): exige juicio humano y por lo tanto pasa por el flujo de cuatro ojos.

Una política `Deny` **no revierte lo ya desplegado**: los recursos anteriores a la asignación aparecen como no conformes hasta corregirse. Esa asimetría es la razón de que los tres momentos convivan y no se sustituyan.

12.3 Control de cambios de infraestructura (four-eyes)

Todo cambio irreversible sobre Azure originado en la plataforma atraviesa `RemediationApprovals` :



La separación entre `APPROVED` y `FAILED` es deliberada a nivel de arquitectura: **el ahorro reportado al negocio sólo incluye lo que Azure confirmó**. Una aprobación que ARM rechazó no liberó un peso, y contarla inflaría la métrica que sostiene el caso de negocio de la plataforma.

12.4 Postura de seguridad e identidad

- **Ciclo de vida de credenciales de Entra ID.** Auditoría de secretos y certificados de App Registrations con alertas multi-umbral previas al vencimiento. La rotación es aditiva por diseño —crea sin revocar— porque revocar y migrar en un solo paso es la causa habitual del incidente que el módulo previene.
- **Auditoría de SIDs huérfanos.** Asignaciones RBAC cuyo principal ya no existe en el directorio. No otorgan acceso a nadie hoy, pero si el `objectId` se reutiliza el permiso revive sobre otro principal.
- **Score de Seguridad Financiera.** Índice ponderado de cuatro pilares (Azure Policy 40%, etiquetas 30%, RBAC 20%, zombis 10%) con **redistribución de peso de los pilares no medibles**: la plataforma nunca afirma una postura que no pudo verificar.

12.5 Resiliencia como decisión económica

El módulo de Alta Disponibilidad presenta cada brecha con su **SLA vigente, el alcanzable y el costo del salto**, traducidos a minutos de caída mensual. La decisión de redundancia deja de ser técnica y pasa a ser una comparación explícita entre minutos de indisponibilidad y dólares por mes, que es la conversación que el negocio puede sostener.

Se distingue entre lo aplicable por API (SKU de IP pública, asociación de backup) y lo que exige rediseño —zonas, Availability Sets, geo-redundancia—: prometer un botón donde hace falta recrear un recurso erosiona la confianza en toda la herramienta.

12.6 Restricción de arquitectura reafirmada

Un componente cliente **no puede importar de un servicio que toque la base de datos**, ni siquiera una función pura alojada allí: el grafo de imports arrastra el driver de MySQL al bundle del navegador. Las funciones compartidas entre servidor y cliente viven en los archivos de tipos o en `src/lib/`.

12.7 Gobernanza de Etiquetas y Hardening de Secretos de Infraestructura

- **Gobernanza de Etiquetas (Azure Tag Governance Engine).** Auditoría automatizada de políticas obligatorias (`Environment`, `Role`, `CostCenter`, `Department`), propagación de etiquetas desde Grupos de Recursos con Merge Seguro e inferencia basada en IA para autocompletar metadatos faltantes.
- **Key Vault Network Isolation.** Aislamiento perimetral completo del almacén de secretos (`cscs-finops-prod-wus2-kv`) mediante Private Endpoint (`privatelink.vaultcore.azure.net`) y directiva `default_action = Deny`, eliminando vectores de acceso público y protegiendo credenciales de tenants en tránsito y reposo.

© 2026 CScCloudSolutions. Todos los derechos reservados. — CONFIDENCIAL

13. Addendum 2026-09-01 — Comunicación con el cliente, ciclo de vida contractual y

capacidad como producto

Tres capacidades nuevas a nivel de arquitectura, más la consolidación del cobro de capacidad. Todas comparten un mismo principio de diseño que conviene explicitar porque se aplicó cuatro veces en la sesión: **cuando un dato es un hecho con su momento, se persiste; cuando es una consecuencia recalculable, se deriva.**

13.1 Canal de comunicación plataforma → tenant

Hasta ahora la plataforma sólo podía hablarle al cliente a través de notificaciones generadas por reglas automáticas (gasto, auditoría). No existía un canal para que un operador humano emitiera un aviso —un mantenimiento, una incidencia— con ventana de vigencia y alcance elegible.

Se incorpora un dominio `SystemAnnouncements` con dos canales de entrega (banner persistente y popup con descarte) y segmentación por tenant. Es transversal: vive en `ClientShell`, por encima de cualquier módulo, y no depende del estado de ningún cockpit.

Decisión de arquitectura relevante: el **estado de un anuncio se deriva de sus fechas**, no se materializa. "Programado", "Activo" y "Finalizado" son la misma comparación contra el reloj; persistirlos habría creado una obligación de sincronización (un cron) para un valor que se recalcula en microsegundos. El contraste con §13.2 es deliberado.

El contenido admite traducciones opcionales por idioma, con caída al idioma base. La opcionalidad es una decisión de producto, no una limitación: exigir tres traducciones convertiría la urgencia de un aviso de incidencia en fricción operativa.

13.2 Ciclo de vida contractual del tenant

La plataforma conocía el estado actual de una suscripción, pero no su historia: no había forma de calcular churn, LTV ni retención por cohortes porque las fechas de alta, suspensión y baja no se registraban en ningún lado.

Se incorpora un modelo de dos capas —**estado actual denormalizado** en `Tenants` para el filtrado del panel, e **historial append-only** en `TenantLifecycleEvents` para el análisis— y, más importante, **un único punto de transición** por el que pasan webhooks, crons y acciones administrativas. Antes había 17 escrituras directas del estado, cada una libre de olvidarse del registro; ahora el registro es consecuencia de la transición.

Acá el dato **sí se persiste** aunque parezca derivable: un tenant que se da de baja y vuelve tiene varios períodos, y el estado actual sólo conserva el último. La historia no se puede reconstruir después a partir del presente.

13.3 Capacidad como producto cobrable

La capacidad (suscripciones de Azure, tenants vinculados) pasa de ser un límite fijo por plan a ser **capacidad base + capacidad comprada**, con el add-on gestionado como ítem de la suscripción existente en el proveedor de pagos.

El principio de integridad que gobierna el diseño: **la capacidad la acredita el webhook, nunca la ruta de compra**. La API solicita el cambio al proveedor; sólo cuando éste confirma, la plataforma escribe. Y se *fija* desde la cantidad vigente en la suscripción en vez de incrementar, lo que hace el mecanismo naturalmente idempotente y hace que la baja del add-on devuelva la capacidad sin código adicional.

Ningún price ID configurado equivale a "add-ons deshabilitados": el sistema no toca la capacidad de nadie, para no pisar con ceros lo asignado comercialmente a mano.

13.4 Exactitud del dato de costo por etiqueta

El costo llega por dos caminos con propiedades distintas: el export FOCUS (exacto, con etiquetas y `ResourceId`) y la Query API de Cost Management (agregada, sin etiquetas). La plataforma ahora **distingue explícitamente** cuál de los dos alimentó un período y degrada de forma consciente: con dato exacto usa el predicado por etiqueta y evita una llamada a Resource Graph; sin él, cae a la aproximación por Resource Group y **lo informa** (`tagMatchIsApproximate`).

Se suma un tercer origen para tenants sin export: un desglose por etiqueta obtenido de Cost Management en su propia tabla. Vive separado del agregado principal porque es *el mismo dinero visto por otra dimensión*: mezclarlo haría que cualquier consumidor que sume sin filtrar cuente doble. Es la misma convención que ya seguían los desgloses por medidor y por categoría.

13.5 Plataforma de ejecución

Se retiran los últimos artefactos del despliegue anterior sobre VPS. La plataforma corre exclusivamente sobre **Azure Container Apps** (build en ACR, migraciones como Container App Job, OIDC federado sin llaves SSH) desde el 2026-07-27. Los documentos que registran la migración y el aviso legal de cambio de subencargado se conservan: son el porqué de la arquitectura actual y una obligación contractual, respectivamente.

14. Addendum 2026-09-03 — Rendición de cuentas del desvío, integridad del modo demo y canal Marketplace

14.1 El desvío como unidad de trabajo, no como dato

Hasta ahora la plataforma detectaba anomalías de gasto y las mostraba. Detectar es la mitad barata del problema: **un desvío que nadie toma es equivalente a un desvío no detectado**, y cuesta más, porque consume atención sin producir acción.

Se completa el ciclo con tres piezas que convierten el hallazgo en trabajo asignado: un estado de triaje que persiste con autoría, un responsable derivado del modelo de gobernanza del cliente, y una notificación dirigida a esa persona.

El principio de diseño que gobierna la asignación: **la plataforma no inventa dueños**. La responsabilidad se deriva de lo que el cliente ya declaró — sus Cost Groups con dueño, o la etiqueta `Owner` que audita el módulo de Gobernanza de Etiquetas — y cuando ese modelo no alcanza, el desvío se muestra explícitamente como "sin asignar".

Eso no es una limitación disimulada: asignarle un desvío a quien no corresponde entrena a esa persona a ignorar las alertas, y ahí se pierde el canal completo. El contador de "sin asignar" es, además, el argumento más concreto para que el cliente complete su modelo de etiquetas — convierte una carencia de gobernanza en una lista accionable.

14.2 Integridad del modo demo como propiedad de seguridad

Los datos de demostración son sólo para demostración. Esa regla, que parece obvia, es en realidad una **propiedad de seguridad de datos** en un producto de gestión de costos: si un tenant real ve una cifra inventada, toma una decisión de dinero sobre información falsa, y el error no deja rastro porque los números se ven normales.

La auditoría del mecanismo de demo encontró que podía violarse durante el cambio de tenant, por una asimetría entre cómo se instalaba y cómo se desinstalaba la intercepción. Se corrigió revalidando el contexto en cada llamada en vez de confiar en que la desinstalación llegue a tiempo.

De ahí se desprende un principio más general que conviene explicitar: **todo mecanismo que sustituye datos reales debe revalidar su condición en el momento de servir, no sólo en el momento de instalarse**. El estado de la aplicación cambia entre ambos instantes.

La segunda mitad es de contrato: los generadores de datos de demostración se atan al mismo tipo que devuelve el camino vivo, de modo que un cambio de contrato rompa la compilación en lugar de degradar la demostración en silencio. Una demo divergente no sólo se ve mal ante un prospecto: se usa para validar cambios sin tocar un tenant real, y cuando diverge convierte esa validación en falsos negativos.

14.3 Canal de distribución: Azure Marketplace

Se incorpora el Marketplace de Azure como segundo canal comercial, junto al cobro directo. Arquitectónicamente supone que **el estado de una suscripción puede provenir de dos autoridades distintas**: el proveedor de pagos propio y Microsoft.

Por eso el estado reportado por Microsoft se persiste **separado** del estado comercial de la plataforma. Unificarlos sería más simple y estaría mal: una suspensión originada en Azure pisaría el motivo real de una baja gestionada por otro canal, y ante una conciliación con Partner Center no se podría explicar el origen de cada transición.

Se registran además los datos de conciliación —oferta, comprador y directorio comprador—, porque quien compra no siempre es quien después usa la plataforma, y esa distinción es la que Microsoft pide para resolver un reclamo de facturación.

La verificación criptográfica del webhook no es opcional: sin ella, el endpoint de ciclo de vida es una vía pública para alterar el plan de cualquier tenant.

15. Addendum 2026-09-04 — Dos modelos de acceso, y la contención como problema de arquitectura

15.1 La autoridad del token es una decisión de arquitectura, no un detalle de implementación


Hasta esta fecha la plataforma tenía **un solo** modelo de acceso a las suscripciones del cliente, y estaba implícito en el código: un App Registration en el directorio **del cliente**, cuyas credenciales guardamos por tenant. Todo `getAzureCredential(tenantId)` construía la credencial contra el tenant del cliente, porque no había otra posibilidad.

Azure Lighthouse no es "otra forma de onboarding": **invierte la autoridad del token**. El Service Principal vive en nuestro directorio, el token se emite contra el nuestro, y ARM lo resuelve hacia las suscripciones que el cliente delegó. Es la diferencia entre "el cliente nos da una identidad

en su casa" y "el cliente le da permiso a nuestra identidad".

Esa distinción tiene consecuencias que no se ven en un diagrama de cajas:

- **No hay plano de datos.** Lighthouse delega plano de control. Nada de leer secretos del Key Vault del cliente, ni blobs de su storage. Cualquier capacidad que dependa de eso simplemente no existe para un tenant delegado.
- **Los management groups no se delegan.** La delegación es por suscripción, así que el scope agregado de Cost Management —el más barato— no está disponible. Todo consumo tiene que consultarse suscripción por suscripción.
- **La revocación es del cliente y es silenciosa.** No expira un secreto que podamos monitorear: el cliente quita la delegación desde su portal y lo que vemos es un 403, o directamente cero suscripciones.



El principio que gobierna el interruptor: `Tenants.access_model` sólo se enciende cuando Resource Graph **confirma** la delegación desde nuestro directorio. Encenderlo al emitir la plantilla dejaría al tenant sin datos hasta que el cliente la desplegara, y la plataforma no tiene forma de saber cuándo eso pasa salvo preguntándole a Azure. Simétricamente, **no se apaga solo**: un fallo puntual de ARG devolvería al tenant al modelo anterior, cuyas credenciales probablemente ya no existan. El único apagado automático es la baja explícita de la última delegación, que es una acción humana.

15.2 Lighthouse es una capacidad de Enterprise, y el gate vive en el servidor

Restringir Lighthouse a Enterprise no es una decisión comercial arbitraria: el modelo delegado concentra en **una sola credencial** el acceso a las suscripciones de todos los clientes que lo usan. Eso cambia el perfil de riesgo respecto del modelo clásico, donde cada tenant tiene su propio secreto y el compromiso de uno no toca a los demás.

La lección de implementación vale para todo el sistema: **un gate declarado no es un gate aplicado**. `routeTiers` declaraba Lighthouse como Enterprise, pero el panel dejó de ser una página propia y pasó a ser pestaña de un hub; el gate resuelve el tier por `pathname` y el hub filtra por permisos y rol, no por tier. La declaración decía Enterprise y la realidad era "cualquiera".

Por eso el gate efectivo está en las **rutas de API**, no en la UI. Un bloqueo visual se saltea con un `fetch`. Y la ruta de verificación importa tanto como la que emite la plantilla, porque es la que enciende el modelo de acceso.

15.3 La contención sobre APIs de terceros es un problema de arquitectura

El barrido nocturno de costos venía venciendo su techo por tenant y, durante cuatro días, tres de cada cuatro tenants no ingirieron un dato. La causa no era volumen: era **contención**. En la media hora del barrido, Resource Graph registró 5 respuestas 429 y Cost Management 314.

La diferencia entre los dos no era la cuota: era que ARG tenía una **cola global con pausa compartida** y Cost Management no. El backoff por llamada es insuficiente por construcción —mientras un llamador espera su turno, los demás siguen golpeando y renuevan la penalidad. Con los jobs de precalentamiento corriendo cada 10, 15 y 20 minutos, el throttle nunca bajaba.

El patrón queda extraído a un limitador genérico con **estado por instancia**: ARG y Cost Management tienen cuotas independientes, y compartir el `pausedUntil` haría que un 429 de uno frenara al otro sin motivo. La lección arquitectónica es que **el rate limiting de un servicio externo es una propiedad del sistema, no de cada llamada**: cualquier consumidor nuevo de una API de terceros con cuota compartida tiene que entrar por la cola, no traer su propio reintento.

15.4 El límite de suscripciones tiene que ser visible donde se decide

El tope por plan (Professional 2, Business 3, Enterprise sin límite) se aplicaba por truncado silencioso: se ordenaba por GUID y se tomaban los primeros N. Es determinístico —no cambia entre corridas— pero arbitrario desde el punto de vista del cliente: su suscripción de producción podía quedar afuera y su sandbox adentro, sin ninguna señal.

La tabla de Cuentas Cloud mostraba las cuatro suscripciones con la misma apariencia, y el banner decía "2 de 2 permitidas" sin aclarar **cuáles** dos. La salida ya existía en el diseño —desvincular una libera cupo, porque la exclusión se aplica *antes* del truncado— pero era indescubrible.

El principio: **cuando el sistema toma una decisión que el usuario podría tomar mejor, la decisión tiene que ser visible y reversible en el mismo lugar donde se ve su efecto**.

16. Addendum 2026-09-05 — El límite del barrido secuencial, y la señal que se pierde

16.1 Secuencial por tenant es una decisión correcta con una fecha de vencimiento

Los barridos por tenant —costos, precalentamiento, backfill, detección de anomalías— se procesan **en serie**. La razón está bien fundada: correrlos en paralelo amplifica el 429 de Cost Management en vez de evitarlo, y un tenant que agota sus reintentos pierde el día entero de datos.

Pero secuencial significa **tiempo lineal en la cantidad de tenants**, y eso choca contra un límite fijo:

$$\begin{array}{ccccccc} \text{techo por tenant} & \times & N & \text{tenants} & \leq & \text{timeout del job} \\ 10 \text{ min} & \times & N & \leq & 60 \text{ min} & \rightarrow & N \leq 6 \end{array}$$

A partir del séptimo tenant el barrido no termina. **No degrada: se corta**. Y los dos límites se comen mutuamente — subir el techo por tenant reduce cuántos entran, bajarlo hace que los lentos no completen.

El principio a registrar: **una decisión de diseño correcta puede tener un techo aritmético que no se ve hasta que se alcanza**, y el momento de identificarlo es cuando se elige, no cuando se choca. Acá el techo ya se estaba alcanzando — **historical-gap-backfill** llevaba días sin completar una sola corrida— y se leía como "un job que falla", no como "el diseño llegó a su límite".

Las salidas reales son dos, y ninguna es un ajuste de parámetros: un job por tenant, con paralelismo acotado y techo propio; o una cola de trabajo con workers. Mientras tanto, un **presupuesto de tiempo con orden rotado** convierte un barrido que nunca termina en uno que avanza parcialmente y de forma pareja.

La rotación es lo que hace aceptable al presupuesto. Sin ella, acotar el tiempo es peor que no acotarlo: los mismos tenants se procesan siempre primero y los últimos no se procesan nunca. El presupuesto sin rotación no reparte el trabajo, elige perdedores fijos.

16.2 El estado de un job es una señal, y tiene que distinguir grados

Sobre ~300 ejecuciones de cron en rojo, **ninguna era un problema del trabajo**. Tres modos de falla, y los tres comparten una forma: el sistema tenía la información correcta y la perdía al cruzar un borde.

- Un barrido con 4 de 5 tenants OK se reportaba igual que uno con 0 de 5. La aplicación sí lo clasificaba como **warning**; el exit code, que es lo único que la plataforma mira, sólo admite éxito o fracaso.
- Un barrido que superaba el techo de la plataforma HTTP se reportaba como fallido aunque completara del lado del servidor.
- Un job que terminaba en 107 ms se reportaba como fallido porque el proceso salía antes de que la plataforma registrara su código.

El costo de esto no es el ruido: **es la señal**. Con cien alertas falsas por día, una alerta legítima es indistinguible del fondo. Un sistema de alertas con 50% de falsos positivos no está degradado — está apagado, y encima da la impresión contraria.

El criterio que queda: **el estado que se publica hacia afuera tiene que preservar los grados que el sistema ya conoce internamente**. Colapsar "parcialmente bien" a "mal" es tirar información que costó producir, en el único punto donde alguien la iba a leer.

17. Addendum 2026-09-07 — El payload no conoce el idioma del lector, y el TTL duro no es fresca

17.1 La prosa generada en el servidor es una decisión de arquitectura, no de redacción

Un barrido sobre **intelligence/** encontró el mismo defecto en cuatro módulos independientes: el servidor **armaba el texto** que iba a leer el usuario y lo metía en el payload.

Servidor (sin locale)		Cliente (con locale)
recommendation: "Réplicas mínimas fijadas en > 1 sin tráfico 24/7."	→	{svc.recommendation} (UI en inglés, texto en español)

El servidor no tiene locale, y no puede tenerlo de forma confiable: el mismo payload se cachea en Redis y se sirve a lectores distintos. Una vez que la prosa entra al envelope, **el idioma queda congelado en el momento de la recolección**, no en el de la lectura.

Lo llamativo es que en los cuatro casos el payload **ya llevaba el discriminador** — `remediationActionKey`, `actionKey`, `type`, `serviceKey` — y la prosa era información redundante que además era incorrecta. El catálogo de traducciones existía y estaba completo; en nueve claves nadie lo leía nunca.

El criterio que queda: un payload cacheado y compartido entre lectores transporta *hechos y claves*, nunca texto para humanos. Si el servidor eligió una rama de negocio, lo que viaja es cuál rama eligió — el nombre de esa rama en el idioma del lector lo resuelve el borde que sí conoce el locale.

El corolario operativo: **las claves que se arman en runtime son invisibles para el verificador de integridad de i18n**. `t(\ rc_rec_{$key})`` no aparece en ningún grep de literales, así que un catálogo puede quedar incompleto y la UI renderiza el nombre crudo de la clave sin que nada falle. Cada familia de claves dinámicas necesita su propio test que recorra el dominio del discriminador.

17.2 El TTL duro de un caché es una propiedad de disponibilidad

Una ruta pesada devolvía `524` desde el CDN (timeout de origen, 100 s) y "después de un rato cargaba bien, y al rato otra vez no". Estaba cacheada con stale-while-revalidate, que es exactamente el patrón correcto. El TTL era 30 min.

La confusión de fondo es tratar el TTL duro como si midiera frescura. No la mide:

	QUÉ CONTROLA	SI ES CORTO
TTL blando	cuánto se sirve antes de revalidar en background	se revalida seguido; nadie espera
TTL duro	cuánto tiempo existe una entrada	la entrada desaparece y el lector siguiente paga el cálculo sincrónico

Vencido el TTL duro, el patrón deja de protegerte: no hay nada stale que devolver, y el request se convierte en el cálculo completo. Si ese cálculo supera el techo del CDN, el resultado es un error que **no se manifiesta como lentitud sino como caída**, y de forma intermitente — una vez por vencimiento.

El criterio: en una ruta cuyo cálculo en frío se acerca al techo de la capa HTTP, el TTL duro se dimensiona para que **siempre haya una entrada**, y la frescura se delega enteramente al TTL blando. Y tiene que ser coherente con la cadencia del precalentamiento: un `prewarm` diario contra un TTL de 30 min deja 23 horas y media de exposición al camino lento.

El caso degradado necesita su propio TTL. Cachear por un día un payload que salió incompleto por un 429 transitorio congela un número equivocado; el TTL dinámico lo baja a minutos para que el refresh siguiente reintente.

17.3 Programa de afiliados: la pasarela de pago queda fuera del camino de confianza

Se incorpora un canal de referidos: un tercero promociona la plataforma con un link propio y devenga un porcentaje recurrente de lo que pagan los tenants que trajo.

El diseño obvio es hacer viajar el código del afiliado por los metadatos de la pasarela (`custom_data`), para que vuelva intacto en el webhook de cobro. Se descartó, y el motivo es de arquitectura:

```
Descartado: link → localStorage → checkout → Paddle → webhook → comisión
              └ el cliente edita el valor acá ┘

Adoptado:   link → cookie → alta del tenant → AffiliateReferrals (servidor)
              ↓
              webhook → tenant_id → referido → comisión
```

La atribución es un **hecho del servidor indexado por tenant**, y el webhook ya resuelve el tenant. Hacerla ida y vuelta por un tercero agrega una superficie donde el cliente puede intervenir justo antes de pagar, y obliga a modificar los siete lugares que construyen sesiones de checkout. El límite de confianza queda en el alta, que ocurre una vez y detrás de una identidad verificada.

El principio: cuando un dato ya vive del lado del servidor y hay una clave para recuperarlo, hacerlo circular por un sistema externo no agrega disponibilidad — agrega una superficie de manipulación y N puntos de integración.

Tres propiedades quedan garantizadas por el **esquema**, no por el código: atribución de primer toque (`uq_referral_tenant`), una comisión por cobro (`uq_commission_transaction`) y unicidad de código de referido. La segunda es la que importa: la pasarela reintrega webhooks

ante cualquier respuesta que no sea 2xx, y una comisión duplicada es dinero pagado dos veces. Un chequeo previo en la aplicación es una condición de carrera; un índice único no lo es.

